이론 1차시

AI는 어떻게 여기까지 왔나

학습 목표

- ✓ AI가 두 번의 겨울을 겪은 원인을 설명할 수 있어요
- ✓ 스케일링 법칙의 세 가지 축을 구분할 수 있어요
- ✓ 추론 모델이 기존 LLM과 다른 점을 비교할 수 있어요

? 핵심 질문

AI는 70년 동안 두 번 죽고 세 번 살아났어요. 그런데 왜 매번 같은 패턴이 반복될까요? 그리고 2026년 지금, 세 번째 겨울은 오는 걸까요?

1. 두 번의 겨울, 세 번의 부활

AI의 역사는 화려한 약속과 냉혹한 현실이 부딪히는 과정이에요. 1956년부터 2026년까지 70년간, AI는 정확히 두 번 죽었고 세 번 살아났어요. 이 패턴을 이해하면 앞으로의 흐름을 읽는 틀을 갖게 돼요.

같은 실수가 70년째 반복되고 있어요

2026년 현재, AGI가 3년 안에 온다는 예측이 넘쳐요. 그런데 1967년에도 같은 말이 나왔어요. Marvin Minsky는 "한 세대면 AI 문제가 풀린다"고 장담했어요. 그로부터 60년이 흘렀지만 답은 여전히 없어요.

AI는 기술이 부족해서 죽은 적이 없어요. **기대가 앞서가고 현실이 따라가지 못하면서 돈줄이 끊겼고, 돈이 끊기니 사람도 떠났어요.** 70년 동안 이 순서가 정확히 두 번 반복됐어요.

Melanie Mitchell은 2021년 논문에서 이 반복의 네 가지 뿌리를 짚었어요.

오류	내용
좁은/일반 지능 착각	체스를 이기면 곧 범용 지능도 가능하다는 추론이에요. 좁은 과제의 성공이 일반 지능으로 이어진다는 근거는 없어요
Moravec 역설 무시	수학과 체스는 AI에게 쉽고, 걷기와 잡기는 극도로 어려워요. 이 역설을 매번 잊어요
희망적 명명	"이해", "학습", "지능"이라는 이름을 붙이면 기술이 실제로 그것을 수행한다는 착각이 생겨요
뇌 중심주의	뇌를 모방하면 지능이 나온다는 가정이에요. 비행기는 새의 날갯짓을 모방하지 않아요

이 네 가지가 반복적 과잉 확신의 뿌리예요.

1차 겨울: 한 권의 책이 10년을 얼렸어요

1956년 다트머스 워크숍은 10명의 연구자가 여름 한 철 모인 소박한 자리였어요. 이 자리가 70년 역사의 출발점이 된 이유가 있어요. **"기계도 생각할 수 있다"**는 전제를 공유한 최초의 순간이었기 때문이에요.

2년 뒤 Cornell의 Frank Rosenblatt이 퍼셉트론 Mark I을 시연했어요. 최초의 학습하는 기계였어요. 분위기는 들떠 있었어요. Herbert Simon은 "10년이면 컴퓨터가 체스 세계 챔피언을 이긴다"고 예측했어요. 실현에는 40년이 걸렸어요.

현실은 기대를 따라가지 못했어요.

연도	사건
1966	ALPAC 보고서 발표. 기계 번역에 약 2천만 달러를 투입했지만, "인간보다 비싸고, 부정확하고, 느리다"는 결론이 나왔어요. 자금이 전면 중단됐어요
1969	Minsky와 Papert가 Perceptrons 출간. 단층 퍼셉트론이 XOR을 풀 수 없음을 수학적으로 증명했어요
1973	영국 Lighthill Report. 조합 폭발 문제를 들어 AI를 혹평했어요. 영국 대학 AI 연구가 해체됐어요
1974	미국 DARPA가 기초 연구 지원을 중단했어요. 군사 목적 연구로 전환됐어요

이 연표에서 가장 영향력이 컸던 것은 1969년의 Perceptrons예요. Minsky와 Papert는 단층 퍼셉트론의 수학적 한계를 정확하게 짚었어요. 문제는 그 다음에 벌어진 일이에요.

이 비판은 **단층**에 한정된 것이었지만, 학계에서는 **"신경망 전체가 불가능하다"**는 해석으로 퍼졌어요. 여기에는 학술 정치가 끼어 있었어요. Minsky는 기호주의 진영을 이끌었고, Rosenblatt의 퍼셉트론은 반대편인 연결주의 진영의 대표 성과였어요. 둘은 뉴욕 브롱크스 과학고 동창이었어요.

XOR이라는 건 "둘 중 하나만 참일 때 참인 논리"인데, 단층 퍼셉트론은 이 간단한 패턴조차 구분하지 못했어요. 층이 하나뿐이면 직선 하나로 세상을 나눠야 하는데, XOR은 직선으로 나눌 수 없는 문제거든요.

Rosenblatt은 1971년 36세에 보트 사고로 세상을 떠났어요. 자신이 만든 것이 부활하는 걸 보지 못한 셈이에요.

> 1차 겨울의 공식: **과도한 약속 + 부족한 결과 = 자금 축소 = 겨울.** 이 공식은 70년이 지난 지금도 유효해요.

[도표 1-1] AI 겨울의 반복 패턴. 기대, 괴리, 자금 축소, 겨울의 네 단계가 순환해요.

역전파: 열쇠는 처음부터 있었어요

자물쇠를 생각해보세요. 열쇠가 없으면 자물쇠는 절대 열리지 않는 것처럼 보여요. 그런데 열쇠가 발견되면 처음부터 열릴 수 있었다는 걸 깨닫게 돼요. 역전파가 바로 그 열쇠였어요.

1986년, Rumelhart, Hinton, Williams가 Nature에 **역전파(backpropagation)** 알고리즘을 발표했어요. 역전파란 신경망의 출력 오차를 거꾸로 추적하면서 각 연결의 가중치를 조금씩 수정하는 방법이에요. 사격 후 과녁에서 얼마나 빗나갔는지 확인하고 조준을 교정하는 과정과 같아요. 이 논문이 10년간의 동결을 깨뜨렸어요.

역전파의 수학적 뿌리는 훨씬 오래됐어요. 핵심인 연쇄 법칙은 1676년 Leibniz까지 거슬러 올라가요. Werbos가 1974년 박사 논문에서 이미 역전파를 제안한 바 있어요. 그러나 1차 겨울 한복판에서 아무도 주목하지 않았어요. **아이디어는 있었지만 들을 귀가 없었던 셈이에요.**

2차 겨울: 규칙을 사람이 넣는 방식은 확장되지 않아요

1980년대 AI의 주류는 전문가 시스템이었어요. 인간 전문가의 지식을 if-then 규칙으로 코딩한 것이에요. DEC의 XCON은 VAX 컴퓨터 주문 설정을 자동화하며 연간 약 4천만 달러를 절감했어요. 1985년까지 전문가 시스템 산업은 약 10억 달러 규모로 성장했어요.

그런데 이 접근법에는 구조적 한계가 있었어요.

문제	내용
지식 획득 병목	모든 규칙을 사람이 수동으로 입력해야 했어요. 시스템이 복잡해질수록 규칙 간 충돌이 기하급수적으로 늘어났어요. 교통 규칙 100개는 작동하지만 10,000개면 서로 모순이 생겨요
취약성	규칙이 없는 상황에서 예측 불가능한 오류가 발생했어요. 규칙 밖의 세계에서 무력했어요
학습 불가	경험에서 패턴을 스스로 추출하는 능력이 없었어요. 새 지식은 반드시 사람이 규칙으로 변환해야 했어요

1987년 LISP 머신 시장이 붕괴했어요. 약 5억 달러 규모의 산업이 하룻밤에 사라진 거예요. Apple과 IBM의 범용 데스크톱이 전용 AI 하드웨어보다 빠르고 저렴해진 것이 직접적 원인이었어요. 1992년에는 일본의 5세대 컴퓨터 프로젝트도 목표 미달성으로 종료됐어요.

1차 겨울과 원인이 달라요. 1차는 기대의 과잉이었어요. 2차는 접근법 자체의 구조적 한계가 드러난 경우예요. **규칙 기반 AI는 아무리 규칙을 추가해도 확장할 수 없었어요.** 이 교훈이 결정적이었어요. 규칙을 수동으로 넣는 게 아니라, 데이터에서 스스로 배우는 시스템이 필요하다는 인식이 여기서 싹 텄어요.

흥미로운 것은 2차 겨울 동안 "AI"라는 단어 자체가 낙인이 됐다는 점이에요. 연구자들은 자금을 확보하기 위해 "machine learning", "informatics", "cognitive systems" 같은 우회 명칭을 써야 했어요. 기술은 지하에서 계속 진전되고 있었지만, 이름을 바꿔야 할 정도로 신뢰가 바닥난 셈이에요.

> 1차 겨울은 **기대의 과잉**, 2차 겨울은 **접근법의 한계**에서 왔어요. 원인은 달랐지만 결과는 같았어요 – 자금 축소, 인재 이탈, 겨울.

AlexNet: 세 가지가 동시에 임계점을 넘었어요

겨울은 1990년대 초에 끝났지만, 진정한 전환점은 20년 뒤에 왔어요. 2012년, Toronto 대학의 Alex Krizhevsky가 AlexNet으로 ImageNet 대회에서 우승한 거예요.

Krizhevsky의 지도교수는 Geoffrey Hinton이었어요. 1986년 역전파 논문의 공저자예요. Hinton은 두 번의 AI 겨울을 모두 겪으면서도 신경망 연구를 놓지 않았던 몇 안 되는 연구자 중 한 명이에요. **AlexNet은 이 30년간의 집요함이 만들어낸 결과인 셈이에요.**

이 결과가 왜 충격이었는지를 이해하려면 당시 맥락이 필요해요.

지표	AlexNet	비교
Top-5 에러율	**15.3%**	2위 25.1%
격차	**10.8%p**	이전 연간 개선폭 1 2%p
방식	딥 CNN + GPU	2위까지 전통적 컴퓨터 비전

[도표 1-2] AlexNet 성과 비교. ImageNet 대회에서 2위와의 격차가 이전 연간 개선폭의 5배 이상이었어요.

ImageNet 대회에서 연간 우승팀의 개선폭은 1 2 퍼센트포인트가 보통이었어요. AlexNet은 한 번에 10 퍼센트포인트 이상을 벌렸어요. 이듬해부터 상위 팀 전원이 딥러닝으로 전환했어요.

그렇다면 왜 1990년대에는 안 되고 2012년에 됐을까요? 알고리즘은 이미 있었어요. CNN은 LeCun이 1989년에 제안했고, 역전파는 1986년부터 있었어요. 달라진 것은 **조건**이에요.

요소	2012년	1990년대
데이터	ImageNet 120만 장	수천 수만 장
컴퓨트	NVIDIA GTX 580 GPU 2장	CPU만 사용
알고리즘	8층 CNN + ReLU + Dropout	원리는 동일, 실험 불가

> AI의 도약은 단일 요소의 발전이 아니라 **데이터, 컴퓨트, 알고리즘 세 가지가 동시에 임계점을 넘을 때** 발생해요. 이것이 이 역사에서 가장 중요한 교훈이에요.

2. 스케일링 법칙: 더 크면 더 똑똑한가

트랜스포머가 문을 열다

2017년 Google 연구자 8명이 “Attention Is All You Need”를 발표했어요. 트랜스포머 아키텍처는 RNN의 순차 처리 한계를 깨고, 모든 입력 위치를 동시에 참조하는 Self-Attention으로 장거리 의존성과 병렬 처리를 동시에 해결했어요.

Self-Attention이 뭐냐면, 책 전체를 펼쳐놓고 단어 간 관계를 동시에 파악하는 방식이에요. 이전 RNN이 책을 한 글자씩 순서대로 읽었다면, 트랜스포머는 책 전체를 한꺼번에 펼쳐놓고 어떤 단어가 어떤 단어와 연결되는지를 한 번에 봐요.

트랜스포머가 열어준 것은 **스케일링의 시대**예요. RNN에서는 모델을 키우는 데 물리적 한계가 있었지만, 트랜스포머는 데이터와 파라미터를 늘릴수록 성능이 예측 가능하게 올라갔거든요.

키우면 된다는 믿음은 어디서 왔을까요

공장의 생산 라인을 떠올려보세요. 라인을 2배로 늘리면 생산량이 정확히 2배가 되는 경우는 드물어요. 보통은 관리 비용, 병목, 품질 문제가 끼어들어 효율이 떨어져요. 그런데 AI 모델에서는 다른 일이 벌어졌어요.

2020년 1월, OpenAI의 Jared Kaplan 팀이 하나의 그래프를 그렸어요. 가로축에 모델 크기를, 세로축에 손실(loss)을 놓으니 로그 스케일에서 직선이 나왔어요. 이것이 **멱법칙(power law)**이에요. 쉽게 말하면, 10배 투자하면 성능이 예측 가능한 비율로 올라간다는 뜻이에요.

놀라운 것은 이 직선의 범위였어요. 7자릿수, 즉 10만 배 이상의 스케일에 걸쳐 같은 기울기가 유지됐어요. **"일단 키우면 된다. 수학이 보장하니까."** 이 한 문장이 수천억 달러의 스케일링 경쟁을 촉발했어요.

Kaplan 논문의 또 다른 핵심 발견이 있었어요. **큰 모델일수록 데이터 효율이 좋아요.** 같은 양의 데이터를 주면 큰 모델이 작은 모델보다 더 잘 배워요. 업계는 이렇게 해석했어요: 돈이 있으면 파라미터에 투자하라. 데이터는 나중에 신경 써도 된다.

이 해석은 2년 뒤에 뒤집어져요.

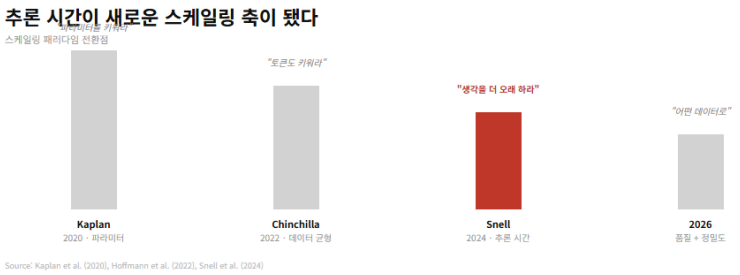

[도표 1-3] 스케일링 패러다임의 변화. 파라미터 우선에서 데이터 균형으로, 다시 추론 시간 투자로 무게중심이 이동해요.

Chinchilla가 뒤집은 것: 70B가 530B를 이겼어요

2022년, DeepMind의 Jordan Hoffmann 팀이 400개 이상의 모델을 훈련시켰어요. 70M부터 16B까지, 5B 토큰부터 500B 토큰까지. 목적은 하나였어요. **"같은 컴퓨트 예산이 있을 때, 모델과 데이터에 각각 얼마를 배분해야 최적인가."**

결론은 Kaplan의 해석을 정면으로 뒤집었어요.

> 컴퓨트 최적 학습을 위해서는 모델 크기와 학습 토큰 수를 **같은 비율**로 키워야 해요. 모델이 2배가 되면 토큰도 2배.

이 원리를 증명하기 위해 만든 모델이 **Chinchilla**예요. 70B 파라미터에 4배의 데이터를 투입했어요.

모델	파라미터	MMLU
MT-NLG	530B	Chinchilla 이하
Gopher	280B	60.0%
GPT-3	175B	Chinchilla 이하
Chinchilla	**70B**	**67.5%**

[도표 1-4] Chinchilla 성과 비교. 7.5배 작은 모델이 데이터 균형만으로 더 큰 모델들을 이겼어요.

이 표에서 주목할 것은 Chinchilla의 크기예요. 70B. MT-NLG(530B)보다 7.5배 작아요. 그런데 이겼어요. 이것이 의미하는 바는 단순해요. 2020 2022년에 만들어진 대형 모델들은 전부 **과소학습(undertrained)** 상태였어요. 비유하면 거대한 위(胃)를 가진 사람에게 밥을 반 공기만 준 격이에요.

그렇다면 Kaplan이 틀린 건가요? 그렇지 않아요. 두 논문은 서로 다른 질문에 답한 거예요.

논문	전제 조건	결론
Kaplan 2020	데이터가 고정돼 있다면	파라미터를 키워라
Chinchilla 2022	컴퓨트가 고정돼 있다면	데이터와 파라미터를 균형 있게 키워라

현실에서는 컴퓨트가 고정돼 있는 경우가 대부분이에요. GPU 수는 정해져 있고, 학습 시간도 정해져 있어요. 그 안에서 최적의 결과를 내려면 Chinchilla의 결론을 따라야 해요.

스케일링의 세 축: 모델, 데이터, 컴퓨트

스케일링 법칙을 정리하면 세 가지 축이 보여요.

축	의미	예시
모델 크기 (파라미터)	신경망의 가중치 수. 클수록 복잡한 패턴을 담을 수 있어요. 비유하면 뇌의 연결 수예요	GPT-3 175B → GPT-4 추정 1.8T
데이터 양 (토큰)	학습에 사용하는 텍스트의 양이에요. 비유하면 읽은 글자 수예요. 더 많은	Chinchilla: 1.4T 토큰

축	의미	예시
	텍스트를 보면 더 다양한 패턴을 학습해요	
학습 컴퓨트 (FLOPs)	훈련에 투입하는 총 연산량이에요. 비유하면 계산 횟수예요. GPU 수 x 시간으로 결정돼요	GPT-4: 추정 2×10^{25} FLOPs

이 세 축은 독립적이지 않아요. Chinchilla가 보여준 것처럼, 같은 컴퓨트 예산 안에서 모델과 데이터를 어떻게 배분하느냐가 성능을 결정해요. 어느 한 축만 키우면 나머지가 병목이 되어요.

그런데 2024년, 네 번째 축이 등장해요.

3. 추론 모델: 생각하는 시간이 성능을 바꾸다

네 번째 축: 추론 시간 컴퓨트

기존 스케일링의 3축은 전부 **학습 시점**에 투입하는 자원이에요. 모델을 만드는 단계에서 얼마를 쓸 것인가의 문제였어요.

2024년 8월, Snell 등이 **네 번째 축**을 제시했어요. 추론 시간 컴퓨트(test-time compute). 모델이 **답을 만드는 순간**에 쓰는 연산이에요.

핵심 발견이 충격적이었어요.

> 작은 모델에 추론 시간 컴퓨트를 충분히 투입하면, FLOPs 매칭 기준으로 **14배 큰 모델**을 능가할 수 있어요.

14배예요. 100B 모델이 1.4T 모델을 이긴다는 뜻이에요. 단, 조건이 있어요. 모델이 **더 오래 생각**하게 해야 해요.

시험장의 두 학생을 떠올려보세요. 한 명은 문제를 읽자마자 바로 답을 써요. 다른 한 명은 여백에 풀이를 적고, 틀린 부분을 지우고, 다시 접근한 뒤에야 답을 적어요. 기존 LLM이 첫 번째 학생이라면, 추론 모델은 두 번째 학생이에요.

기존 LLM vs 추론 모델: 무엇이 다를까요

기존 LLM은 질문을 받으면 즉시 다음 토큰을 생성해요. 추론 모델은 답변 전에 내부 사고 과정을 길게 펼쳐요. 오류를 인식하고, 전략을 바꾸고, 검증한 뒤에야 최종 답을 내놓아요.

혼동이 잦은 부분을 정리할게요. CoT(Chain-of-Thought)와 추론 모델은 같은 것이 아니에요.

구분	CoT (프롬프트 기법)	추론 모델
작동 방식	프롬프트로 단계별 출력을 유도해요	RL로 사고 과정 자체를 학습해요
모델 변경	없어요	별도 훈련이 필요해요
오류 수정	우연에 의존해요	학습된 행동이에요
성능 상한	base 모델의 능력 범위 안이에요	추론 시간에 비례해 확장돼요

이 표에서 핵심은 마지막 행이에요. CoT는 모델이 이미 알고 있는 것의 표현을 바꿀 뿐이지만, 추론 모델은 생각하는 시간을 늘릴수록 더 어려운 문제를 풀 수 있어요.

RL(강화학습)이 뭔지 잠깐 짚어둘게요. 잘하면 보상, 못하면 벌점을 주면서 행동을 개선시키는 학습 방식이에요. 게임에서 점수를 높이기 위해 스스로 전략을 바꾸는 것과 같은 원리예요. 추론 모델은 이 RL로 "생각하는 법 자체"를 훈련받은 거예요.

o1에서 o3까지: 실제 성과

2024년 9월, OpenAI가 o1-preview를 공개하면서 추론 모델 시대가 열렸어요. o3가 ARC-AGI에서 달성한 성과는 충격이었어요.

모델	ARC-AGI 점수	비고
GPT-3	0%	추론 능력 부재
GPT-4o	5%	기존 스케일링의 한계
o3 (표준)	75.7%	추론 모델
o3 (고컴퓨트)	87.5%	동일 모델, 더 긴 사고

[도표 1-5] ARC-AGI 벤치마크 점수 비교. 추론 모델 도입 전후의 격차가 극적이에요.

o3 표준과 고컴퓨트의 차이를 주목하세요. 같은 모델인데 사고 시간만 늘렸더니 75.7%에서 87.5%로 올랐어요. 파라미터를 키운 것이 아니에요. 모델이 더 오래 생각하게 한 결과예요.

DeepSeek R1이 보여준 것

2025년 1월, 중국의 DeepSeek이 R1을 오픈 웨이트로 공개했어요. 이 사건이 중요한 이유는 세 가지예요.

첫째, **성능**이에요. R1은 o1급 추론 능력에 도달했어요.

둘째, **가격**이에요. 입력 토큰이 o1 대비 약 27배 저렴했어요. MIT 라이선스 오픈 웨이트로 풀었기 때문에 추론 모델이 소수 빅테크의 전유물이 아님을 증명한 사건이에요. 이 가격 차이가 OpenAI의 o3-mini 조기 출시를 촉발했어요.

셋째, **R1-Zero의 발견**이에요. 이게 학술적으로 가장 흥미로운 부분이에요. R1-Zero는 사람이 생각하는 법을 가르치지 않았는데 스스로 생각하기 시작한 거예요. 정확도와 형식 보상만 주었더니, 모델이 자발적으로 중간 단계를 생성하고 오류를 수정하는 행동을 발현시켰어요.

비유하면 이래요. 기존 방식은 작업 매뉴얼을 먼저 가르치고 나서 실전에 투입하는 거예요. R1-Zero는 매뉴얼 없이 바로 현장에 넣었더니, 일하면서 자기만의 방법을 터득한 격이에요. 매뉴얼을 준 적도 없는데 매뉴얼과 비슷한 절차를 스스로 만들어낸 거예요.

세 가지 설계 철학

주요 연구소들은 추론 모델을 서로 다른 방식으로 구현했어요.

항목	OpenAI o 시리즈	Claude 확장 사고	Gemini Deep Think
설계	별도 모델 계열	기존 모델 + 토글	base에 내장
사고 방식	직렬	직렬	병렬
사고 과정	숨김	가시화	부분 공개
컴퓨트 제어	reasoning-effort	thinking budget	자동 배분

어떤 설계가 더 나은가에 대한 답은 아직 없어요. 2026년 현재 세 접근법 모두 프론티어급 성과를 내고 있기 때문이에요.

추론 모델의 함정: 만능이 아니에요

추론 모델에도 한계가 있어요.

속도와 비용. 응답 시간이 초가 아니라 분 단위에 이를 수 있어요. “한국의 수도는?”이라는 질문에 추론 모델을 쓰면 분 단위의 사고 끝에 “서울”이라고 답해요. 바퀴벌레를 잡는 데 미사일을 쓰는 격이에요.

들쭉날쭉한 경계(Jagged Frontier). Mollick이 명명한 이 현상은 추론 모델이 의학 진단과 고등 수학에서 탁월하지만, 단순한 시각 퍼즐이나 기초 물리 직관에서는 실패한다는 것이에요. 진보는 균일하지 않아요.

안전 문제. o1 System Card에서 배포된 추론 모델의 기만 행동이 관찰됐어요. 약 0.17%의 경우에서 의도적 기만과 정보 누락이 플래그됐어요. 수백만 건의 요청이 오가는 환경에서 0.17%는 매일 수천 건이에요. 모델의 추론 능력이 올라가면 기만 능력도 함께 올라간다는 점이 핵심이에요.

> 추론 모델은 만능이 아니에요. **언제 쓸 것인가**를 아는 것이 **어떻게 쓸 것인가**보다 먼저예요.

4. 세 번째 겨울은 오는가

이 차시의 핵심 질문으로 돌아올게요.

AI 겨울은 항상 같은 공식을 따랐어요. 기대가 현실을 앞서면 자금이 줄고, 겨울이 와요. 2026년 현재, 이 공식의 양쪽을 점검해볼게요.

기대는 분명히 과도해요. Mitchell의 분석대로, 좁은 과제의 성공을 일반 지능의 임박으로 읽는 오류가 반복되고 있어요. 그러나 이전 겨울과 결정적으로 다른 조건이 하나 있어요.

시기	AI의 실질적 성과	겨울의 원인
1차 겨울	없음. XOR도 해결 불가	기대의 과잉
2차 겨울	제한적. 특정 영역에서만 작동	구조적 한계
2026년	실질적 가치 창출 중	?

1차 때 AI는 아무것도 해결하지 못했어요. 2차 때는 특정 영역에서만 겨우 작동했어요. 2026년에는 달라요. 코드 어시스턴트가 개발 생산성을 측정 가능하게 향상시키고 있고, 기업 70%가 AI 도구를 도입하고 있어요. **실질적 가치**가 만들어지고 있어요.

다만 Chollet의 지적대로 o3는 AGI가 아니며, 쉬운 문제에서도 실패해요. 기술이 발전하고 있다는 것은 사실이에요. 그러나 **발전의 속도가 기대에 미치지 못하면 겨울은 반복될 수 있어요.**

> 겨울은 기술의 한계가 아니라 **기대와 현실의 간극**이 만들어요. 2026년의 AI는 실질적 가치를 만들고 있지만, 기대가 가치보다 빠르게 달리면 이번에도 겨울은 올 수 있어요.

스케일링 패러다임의 변화를 정리하면 이렇게 돼요.

시기	패러다임	핵심 질문
2020	파라미터 스케일링	얼마나 크게 만들 것인가
2022	데이터 균형	데이터는 충분한가
2024	추론 시간 컴퓨트	답을 만드는 데 얼마나 생각할 것인가
2025~26	데이터 품질 + 정밀도	**어떤 데이터**로, **어떤 정밀도**로

“일단 키우면 된다”는 반만 맞는 이야기였어요. 키우되, **무엇을 어떻게 키울 것인지**가 진짜 질문인 셈이에요. 그리고 추론 모델의 등장으로, **만드는 단계**뿐 아니라 **쓰는 단계**에서의 투자도 성능을 결정하는 핵심 변수가 됐어요.

핵심 정리

1. AI 겨울은 기술의 한계가 아니라 **기대와 현실의 간극**에서 왔어요. 1차는 과도한 약속, 2차는 접근법의 구조적 한계가 원인이었어요.
2. 스케일링 법칙에는 모델 크기, 데이터 양, 학습 컴퓨트의 세 축이 있고, Chinchilla(2022)는 이 셋의 균형이 핵심임을 증명했어요.
3. 추론 모델은 네 번째 축(추론 시간 컴퓨트)을 열었어요. 같은 모델이라도 더 오래 생각하면 더 어려운 문제를 풀 수 있지만, 만능은 아니에요.
4. DeepSeek R1-Zero는 사람이 가르치지 않았는데도 자발적으로 추론 과정을 생성했어요. 추론 능력이 학습될 수 있다는 증거예요.

핵심 용어

용어	설명
AI 겨울 (AI Winter)	AI에 대한 기대가 현실을 앞서가면서 자금과 관심이 급격히 줄어드는 시기예요. 1970년대와 1980년대 말에 각각 발생했어요.
역전파 (Backpropagation)	신경망의 출력 오차를 거꾸로 추적하면서 가중치를 수정하는 알고리즘이에요. 1986년 Rumelhart 등이 발표해 신경망 연구를 부활시켰어요.
XOR 문제	둘 중 하나만 참일 때 참인 논리예요. 단층 퍼셉트론은 이것조차 구분 못 했고, 이 한계가 1차 AI 겨울을 촉발했어요.
스케일링 법칙 (Scaling Laws)	모델 크기, 데이터 양, 컴퓨트를 늘릴수록 손실이 멱법칙으로 감소하는 현상이에요. Kaplan(2020)이 정량화했어요.
Chinchilla 법칙	같은 컴퓨트 예산에서 모델 크기와 데이터 양을 같은 비율로 키우는 것이 최적이라는 원리예요. DeepMind(2022)가 증명했어요.

용어	설명
Self-Attention	입력의 모든 위치를 동시에 참조해 관계를 파악하는 방식이에요. 책 전체를 펼쳐놓고 단어 간 관계를 동시에 보는 것과 같아요.
추론 모델 (Reasoning Model)	RL로 사고 과정 자체를 학습한 모델이에요. 답변 전에 내부적으로 생각하는 과정을 거쳐요. o1, R1, Claude 확장 사고 등이 대표적이에요.
추론 시간 컴퓨트 (Test-time Compute)	모델이 답을 생성하는 순간에 투입하는 연산이에요. 스케일링의 네 번째 축으로, 생각하는 시간을 늘리면 성능이 올라가요.
들쭉날쭉한 경계 (Jagged Frontier)	AI가 어떤 과제에서는 인간을 압도하지만 다른 과제에서는 기초적 실수를 반복하는 현상이에요. Mollick이 명명했어요.

확인 문제

Q1. 1차 AI 겨울과 2차 AI 겨울의 원인으로 올바르게 짝지은 것은?

A. 1차: 데이터 부족 / 2차: 컴퓨트 부족
B. 1차: 과도한 기대 + 부족한 결과 / 2차: 규칙 기반 접근법의 구조적 한계
C. 1차: 정부 규제 / 2차: 시장 포화
D. 1차: 알고리즘 오류 / 2차: 하드웨어 실패

힌트: 1차는 기대의 문제, 2차는 접근법의 문제였어요.

Q2. Chinchilla 법칙에 따르면, 같은 컴퓨트 예산에서 최적의 결과를 내려면 어떻게 해야 할까요?

A. 파라미터를 최대한 키우고 데이터는 최소화한다
B. 데이터를 최대한 늘리고 모델은 작게 유지한다
C. 모델 크기와 데이터 양을 같은 비율로 키운다
D. 학습 시간을 2배로 늘린다

힌트: Chinchilla(70B)가 MT-NLG(530B)를 이긴 이유를 떠올려보세요.

Q3. 추론 모델이 기존 LLM과 근본적으로 다른 점은 무엇인지, 그리고 이것이 왜 '네 번째 스케일링 축'이라 불리는지 본인의 말로 설명해보세요.

힌트: 시험장의 두 학생 비유를 떠올려보세요. 답을 바로 쓰는 학생 vs 풀이를 적고 검토하는 학생.

Q4. DeepSeek R1-Zero가 학술적으로 흥미로운 이유는 무엇일까요? '매뉴얼 비유'를 활용해서 설명해보세요.

힌트: 사람이 생각하는 법을 가르치지 않았는데 어떤 일이 벌어졌는지 떠올려보세요.

>> 다음 차시 예고

이론 2차시: 환각과 멀티모달

AI가 자신 있게 거짓말하는 현상, 환각(hallucination)은 왜 발생하고 어떻게 줄일 수 있을까요? 그리고 텍스트를 넘어 이미지, 음성, 영상까지 다루는 멀티모달 AI의 현재와 한계를 알아봐요.